

Arquitectura local de inferencia para Youtube2knowledge

Anexo técnico de modelos, Transformer y memoria



NVIDIA DGX Spark GB10

Parakeet RNNT Multilingual + Qwen2.5-7B-Instruct + vLLM

Estado documentado: ASR y LLM saludables

A Arquitectura local de modelos

Youtube2knowledge separa el procesamiento en dos redes especializadas. NVIDIA Parakeet RNNT Multilingual convierte audio en texto; Qwen2.5-7B-Instruct transforma la transcripción en preguntas y respuestas. Después de descargar los artefactos, ambas inferencias permanecen en la DGX Spark.




Figura 1: Pipeline local desde el video hasta el material de estudio.

Tabla 1: Modelos principales desplegados en la GB10.

Etapa	Modelo	Parámetros	Precisión	Responsabilidad
Voz a texto	Parakeet RNNT Multilingual	1.1B	FP16	Reconocimiento de voz en 25 idiomas y variantes.
Texto a conocimiento	Qwen2.5-7B-Instruct	7.61B	BF16	Generación estructurada de preguntas Wh- y respuestas.

B Anatomía de Qwen2.5-7B-Instruct

Qwen2.5-7B-Instruct es un Transformer *decoder-only*. Su configuración publicada especifica 28 bloques, dimensión oculta de 3,584, dimensión intermedia de 18,944, 28 cabezas de consulta, cuatro cabezas Key/Value y vocabulario de 152,064 tokens. La variante cargada por vLLM usa BF16 y un contexto operativo de 32,768 tokens.

La atención relaciona posiciones de la transcripción. La MLP transforma cada posición de manera no lineal y concentra la mayor parte de los parámetros. El conocimiento no está guardado como registros independientes: emerge de patrones distribuidos entre estas matrices.

C Distribución de parámetros y pesos

Cada parámetro BF16 ocupa dos bytes. Por ello, 7.6156 mil millones de parámetros requieren cerca de 15.23 GB decimales, o 14.19 GiB, antes de activaciones y cachés de inferencia.

Tabla 2: Cálculo de parámetros principales.

Componente	Forma conceptual	Parámetros	BF16 aprox.
Embedding	$152,064 \times 3,584$	0.545B	1.09 GB
Atención, 28 capas	Q, K, V y proyección de salida	0.822B	1.64 GB
MLP, 28 capas	Gate, Up y Down	5.703B	11.41 GB
Cabeza de salida	$3,584 \times 152,064$	0.545B	1.09 GB
Total	Incluye normas y sesgos menores	7.616B	15.23 GB

Un bloque Transformer, repetido 28 veces




Figura 2: Flujo interno simplificado de un bloque Qwen2.5.




Figura 3: Distribución aproximada de los 7.61B parámetros de Qwen2.5-7B-Instruct.

Un bloque contiene alrededor de 29.4M parámetros de atención y 203.7M de MLP, para un total cercano a 233.1M. Los 28 bloques reúnen aproximadamente 6.53B parámetros. La tabla de embeddings y la cabeza de salida no comparten pesos en esta configuración.

D Memoria durante la inferencia

Los pesos son sólo una parte del uso de memoria. vLLM también mantiene activaciones temporales, áreas de trabajo CUDA, grafos compilados y la caché KV. Esta última evita recalcular Keys y Values de todos los tokens anteriores cuando el modelo genera el siguiente token.

Con cuatro cabezas KV, dimensión de cabeza 128, 28 capas y BF16, el coste ideal por token es aproximadamente:

$$2 (K,V) \times 4 \text{ cabezas} \times 128 \times 28 \text{ capas} \times 2 \text{ bytes} = 57,344 \text{ bytes/token.} \quad (1)$$

Una secuencia de 32,768 tokens requiere cerca de 1.88 GB decimales de KV antes de considerar concurrencia y alineamientos internos. Grouped Query Attention reduce esta cifra porque 28 cabezas Query comparten sólo cuatro grupos KV.



Figura 4: Categorías de memoria del servicio LLM. El límite es un techo, no un consumo constante.

E Estado de validación

La cadena de modelos alcanzó los siguientes hitos en la DGX Spark GB10:

- Parakeet respondió correctamente a una transcripción de muestra por la API HTTP de NVIDIA NIM.
- El perfil NIM seleccionado corresponde a DGX Spark, FP16, modo offline multilingüe, VAD Silero y diarización Sortformer.
- Qwen2.5-7B-Instruct se cargó en BF16 con FlashAttention 2 mediante vLLM 0.28.0.
- El servidor vLLM informó `Application startup complete` y respondió 200 OK en `/health`.
- Los puertos de ASR y LLM permanecen enlazados a loopback; FastAPI actúa como orquestador local.

F Fuentes técnicas

NVIDIA, Parakeet 1.1B RNNT Multilingual ASR Model Card; Qwen Team, Qwen2.5-7B-Instruct Model Card; y Qwen Team, Qwen2.5-7B-Instruct configuration.